ĐỀ TÀI 1 · DPL302M · TASK 2

# Hệ thống nhận dạng giọng nói tiếng Việt kèm dịch sang tiếng Anh

Báo cáo Tiến độ Task 2: Xử lý Dữ liệu, Thực nghiệm Baseline & Mô hình Đề xuất

**Dương Gia Bảo · Lê Tuấn Kiệt · Hồ Lâm Bảo Đăng · Bùi Ngọc Phương Uyên**
Mã nhóm: ..... · GVHD: .....

# Tổng quan nội dung


| | | | |
|---|---|---|---|
| I | **Xử lý và phân tích dữ liệu**<br>Nguồn, làm sạch, gán nhãn, thống kê, mất cân bằng | **Uyên · Đăng** | slide 3–7 |
| II | **Thực nghiệm hai baseline**<br>Môi trường, Paper và Nhóm, Gap Analysis, theo nhóm dữ liệu | **Bảo · Kiệt · Uyên** | slide 8–12 |
| III | **Proposed Method V1 → V3**<br>Kiến trúc, kết quả, failure cases, V2/V3, ablation | **Kiệt · Bảo** | slide 13–18 |
| IV | **Lỗi và tính khả thi**<br>Kết quả đầu ra, tốc độ, dung lượng, khả thi, kế hoạch Task 3 | **Đăng** | slide 19–22 |

# Thu thập và tổng quan dữ liệu

| Nguồn | Loại | Số mẫu dùng | Định dạng | Dung lượng | License |
|---|---|---|---|---|---|
| **FLEURS vi_vn + en_us** | Online | 2.994 / 361 / 857 bản thu (train/dev/test) | WAV 16 kHz + TSV | 2,9 GB | CC BY 4.0 |
| **VIVOS (test)** | Online | 760 câu, 19 người nói | WAV 16 kHz + TXT | 82 MB | CC BY-NC-SA 4.0 |
| **PhoMT** | Online (gated) | 2.977.999 / 18.719 / 19.151 cặp câu | TXT song song | 501 MB | Chỉ nghiên cứu |
| **Tự thu** | Offline | Không thu thập | – | – | – |

Các trường dữ liệu FLEURS: ID câu FLoRes · tên file · transcript gốc · transcript chuẩn hóa · số mẫu âm thanh · giới tính

**VÍ DỤ MẪU FLEURS**

Âm thanh: 11154206868753468740.wav · ID câu 1262

Tiếng Việt: Ở thành phố Harappa và Mohenjo-daro, hầu như nhà nào cũng có cầu tiêu xối nước nối vào một hệ thống cống rãnh phức tạp.

Tiếng Anh: The cities of Harappa and Mohenjo-daro had a flush toilet in almost every house, attached to a sophisticated sewage system.

# Làm sạch dữ liệu

| Dữ liệu gốc | Có câu Anh | Transcript | Âm thanh | Không trùng |
|---|---|---|---|---|
| vi_vn TSV | ghép theo ID | không rỗng | đọc được | hash SHA-1 |
| **2.994** | **2.927** | **2.927** | **2.927** | **2.927** |

Số bản thu còn lại của tập train sau mỗi bước (dev 361 và test 857 không mất mẫu nào)

| Bước | Cách làm |
|---|---|
| **Missing values** | Bỏ bản thu không có câu tiếng Anh cùng ID FLoRes: train loại 67 (2,2%) |
| **Duplicate** | So hash từng file âm thanh: 0 file trùng. Một câu có nhiều bản thu là thiết kế của FLEURS, không phải trùng |
| **Noise / outlier** | Giữ lại để phân tích: 4 bản thu train và 2 dev dài hơn 30 giây |
| **Chuẩn hóa** | 100% âm thanh 16 kHz; chữ: NFC, viết thường, ký hiệu thành khoảng trắng, giữ dấu tiếng Việt |
| **Chống leakage** | Chia theo ID câu; train–dev, train–test, dev–test: 0 ID trùng, 0 câu trùng nội dung |

# Gán nhãn và độ đồng nhất

| Dataset | Nhãn dùng |
|---|---|
| **FLEURS** | Transcript tiếng Việt gốc + câu tiếng Anh FLoRes cùng ID (bản dịch chuyên nghiệp) |
| **VIVOS** | Transcript gốc của bộ dữ liệu, chia theo người nói |
| **PhoMT** | Cặp câu song ngữ gốc |

## Gán nhãn loại lỗi (Label Studio) cho 100 câu FLEURS dev mà baseline nghe hoặc dịch sai

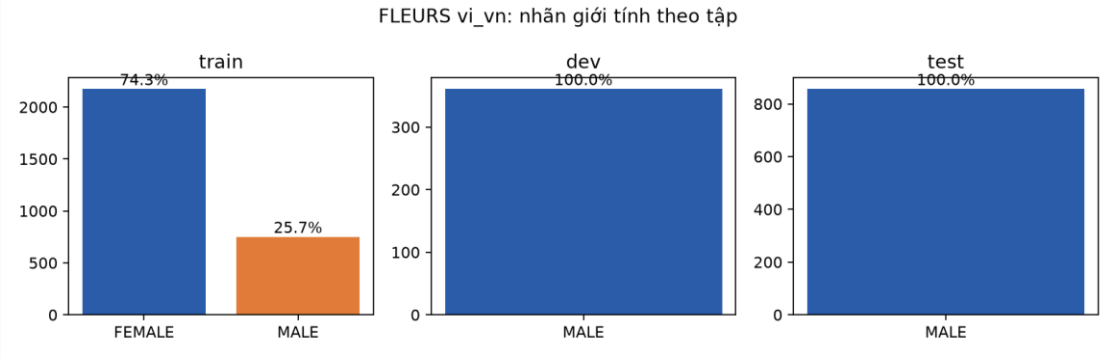
| Sai dấu thanh | Tên riêng | Số | Thiếu / thừa từ | Sai nghĩa |
|---|---|---|---|---|

**CHỜ KẾT QUẢ: Đăng và Uyên gán nhãn độc lập cùng 100 câu → điền Cohen's Kappa vào đây (không điền số khi chưa có)**

Đề Task 2 mục 1.2: Kappa chỉ bắt buộc nếu có quy trình nhiều người gán nhãn.

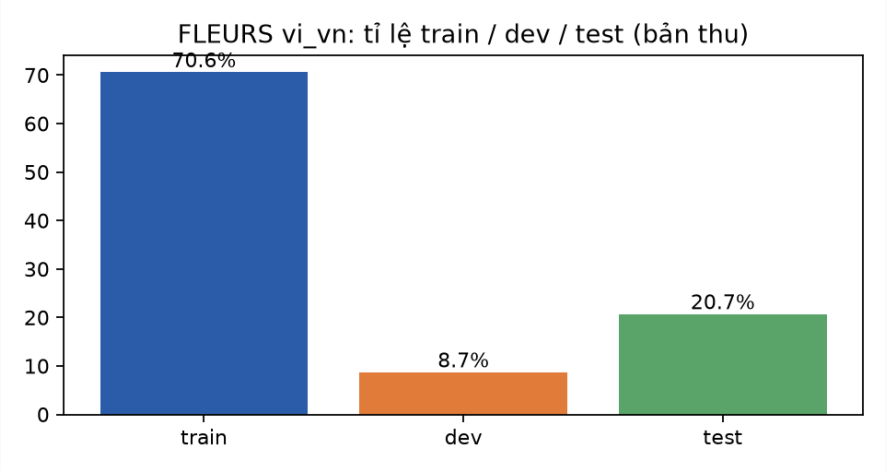
# Thống kê mô tả và mất cân bằng

| | Train | Dev | Test |
|---|---|---|---|
| **Bản thu** | 2.927 | 361 | 857 |
| **Câu gốc** | 1.449 | 149 | 347 |
| **Giờ** | 8,86 | 1,19 | 3,00 |
| **TB giây/câu** | 10,9 | 11,9 | 12,6 |
| **Tỉ lệ** | 70,6% | 8,7% | 20,7% |

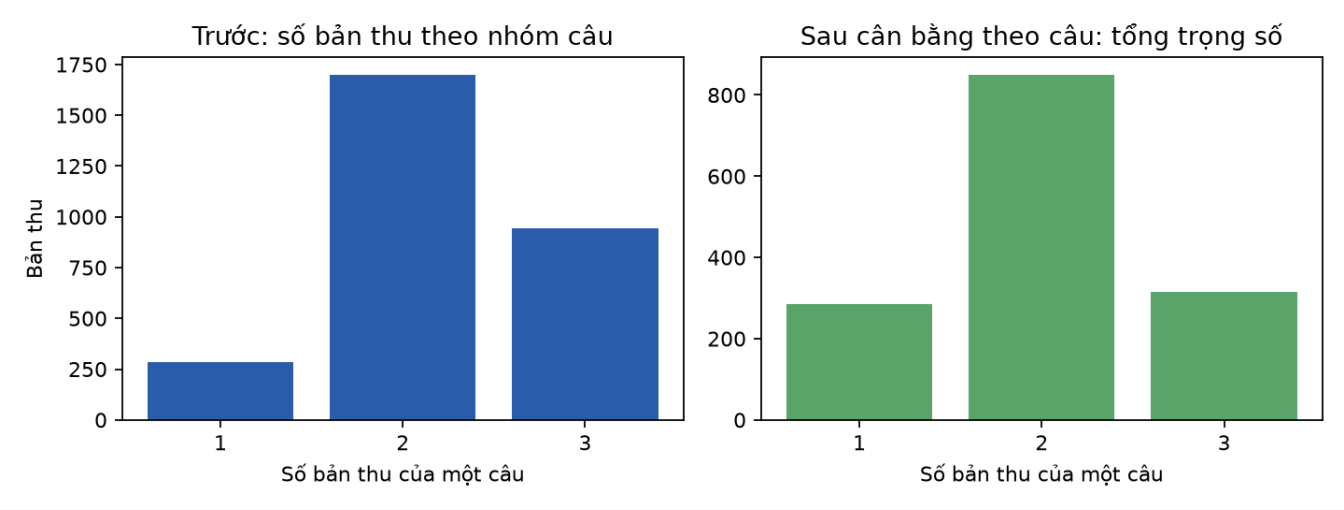



## Nhận xét định lượng

- Giới tính: train 2.175 giọng nữ (74.3%). dev và test 100% giọng nam
- Số bản thu mỗi câu (train): 285 câu có 1, 850 câu có 2, 314 câu có 3
- Độ dài: 52,4% bản thu train dài 10–20 giây, chỉ 63 bản dưới 5 giây
- PhoMT: 51,4% train là phụ đề phim (paper PhoMT)



# Xử lý mất cân bằng




## Kỹ thuật áp dụng

- Resampling theo câu: bản thu của câu có k bản được lấy với trọng số 1/k
- Cân bằng miền khi trộn dữ liệu (V2): thêm 1.449 cặp chữ chuẩn và 3.000 cặp PhoMT
- Không augmentation âm thanh: không train khối nghe
- Lệch giới tính: test không có giọng nữ, ghi là hạn chế

**KẾT QUẢ ĐO**

V2b (V2 + cân bằng theo câu): dev 26,98 so với V2 27,17; test cascade 26,85 so với 27,57

**→ Không cải thiện, không dùng trong bản cuối**

Hình trái: trước (số bản thu theo nhóm câu) và sau cân bằng (tổng trọng số); FLEURS train.

# Cấu hình môi trường thực nghiệm

| Thành phần | Giá trị |
|---|---|
| **Phần cứng** | NVIDIA GeForce RTX 4060 Laptop GPU (8 GB) — một máy cho mọi số so sánh và đo tốc độ |
| **Framework** | Python 3.11.1 · PyTorch 2.6.0+cu124 · Transformers 5.17.0 · PEFT 0.21.2 · sacreBLEU 2.6.0 |
| **Seed / độ chính xác** | 42 · suy luận FP16, train bf16 |
| **Baseline A (ASR)** | PhoWhisper-small, Whisper-small · beam 5 · batch 1 · tiếng Việt |
| **Baseline B (MT)** | VinAI Translate vi2en (bản của paper) · beam 5 |
| **LR · optimizer · epoch** | Baseline: không áp dụng (zero-shot, không train) |
| **V1 → V3 (LoRA)** | AdamW · lr 2e-04 · warmup 6% · batch 8×2 · r 16 · alpha 32 · tối đa 3–5 epoch, chọn theo dev |

# Baseline A: Paper và thực nghiệm của nhóm

| Mô hình | Nguồn | Dataset | WER | CER |
|---|---|---|---|---|
| PhoWhisper-small | Paper (Table 2) | VIVOS test | 6,33 | – |
| **PhoWhisper-small** | **Nhóm** | **VIVOS test (760)** | **6,25** | **3,26** |
| Whisper-small | Nhóm (zero-shot) | VIVOS test (760) | 22,26 | 13,15 |
| PhoWhisper-small | Nhóm | FLEURS test (857) | 12,29 | 8,68 |
| Whisper-small | Nhóm (zero-shot) | FLEURS test (857) | 21,42 | 12,56 |

**Tách lỗi WER của PhoWhisper-small (thay thế / xóa / chèn)**

- VIVOS: 447 / 22 / 14 trên 7.722 từ
- FLEURS: 2.057 / 136 / 1.006 trên 26.021 từ — lỗi chèn nhiều bất thường (xem slide 11)

# Baseline B: Paper và thực nghiệm của nhóm

| Mô hình | Nguồn | Dataset | BLEU | chrF++ |
|---|---|---|---|---|
| VinAI Translate vi2en | Paper (Table 1) | PhoMT test | 40,42 | – |
| VinAI Translate vi2en | Nhóm | PhoMT test (19.151) | 40,27 | 60,32 |
| Dịch chữ chuẩn | Nhóm | FLEURS test (857) | 37,85 | 61,16 |
| **Cascade A → B (B0)** | **Nhóm** | **FLEURS test (857)** | **24,27** | **50,12** |

**−13,58**

### BLEU mất đi khi thay chữ chuẩn bằng chữ máy nghe

Đây là vấn đề Proposed Method nhắm tới. Không dùng vinai-translate-vi2en-v2: khoảng 10 nghìn cặp train của bản này nằm trong PhoMT test.

# Gap Analysis

| Nguyên nhân | Bằng chứng | Ảnh hưởng |
|---|---|---|
| **Khớp công bố** | PhoWhisper 6,25 so với 6,33 · VinAI 40,27 so với 40,42 | Chênh dưới 0,2 điểm: tái lập thành công |
| **Domain gap** | VIVOS 6,25% (cùng miền, PhoWhisper đã học VIVOS train) so với FLEURS 12,21% | FLEURS câu dài hơn (12,6 s so với 3,5 s), đọc văn bản Wikipedia |
| **Tiền xử lý / chuẩn hóa** | Từ bị chèn nhiều nhất trên FLEURS là số: một, hai, trăm, mươi ("802" → "tám trăm linh hai") | WER FLEURS bị đội lên vì khác cách viết số, không hoàn toàn do nghe sai |
| **Môi trường / giải mã** | Whisper-small 25,91% (Task 1) → 22,26%: 750/760 câu giống hệt; câu R193 hết sinh lặp (293 → 4 từ) | PhoWhisper 760/760 câu giống hệt: kết quả ổn định |
| **Cách gom câu khi dịch** | B0 cascade 24,21 → 24,27 khi đổi batch để tránh tràn bộ nhớ | Mọi phiên bản chấm cùng một script và cấu hình |

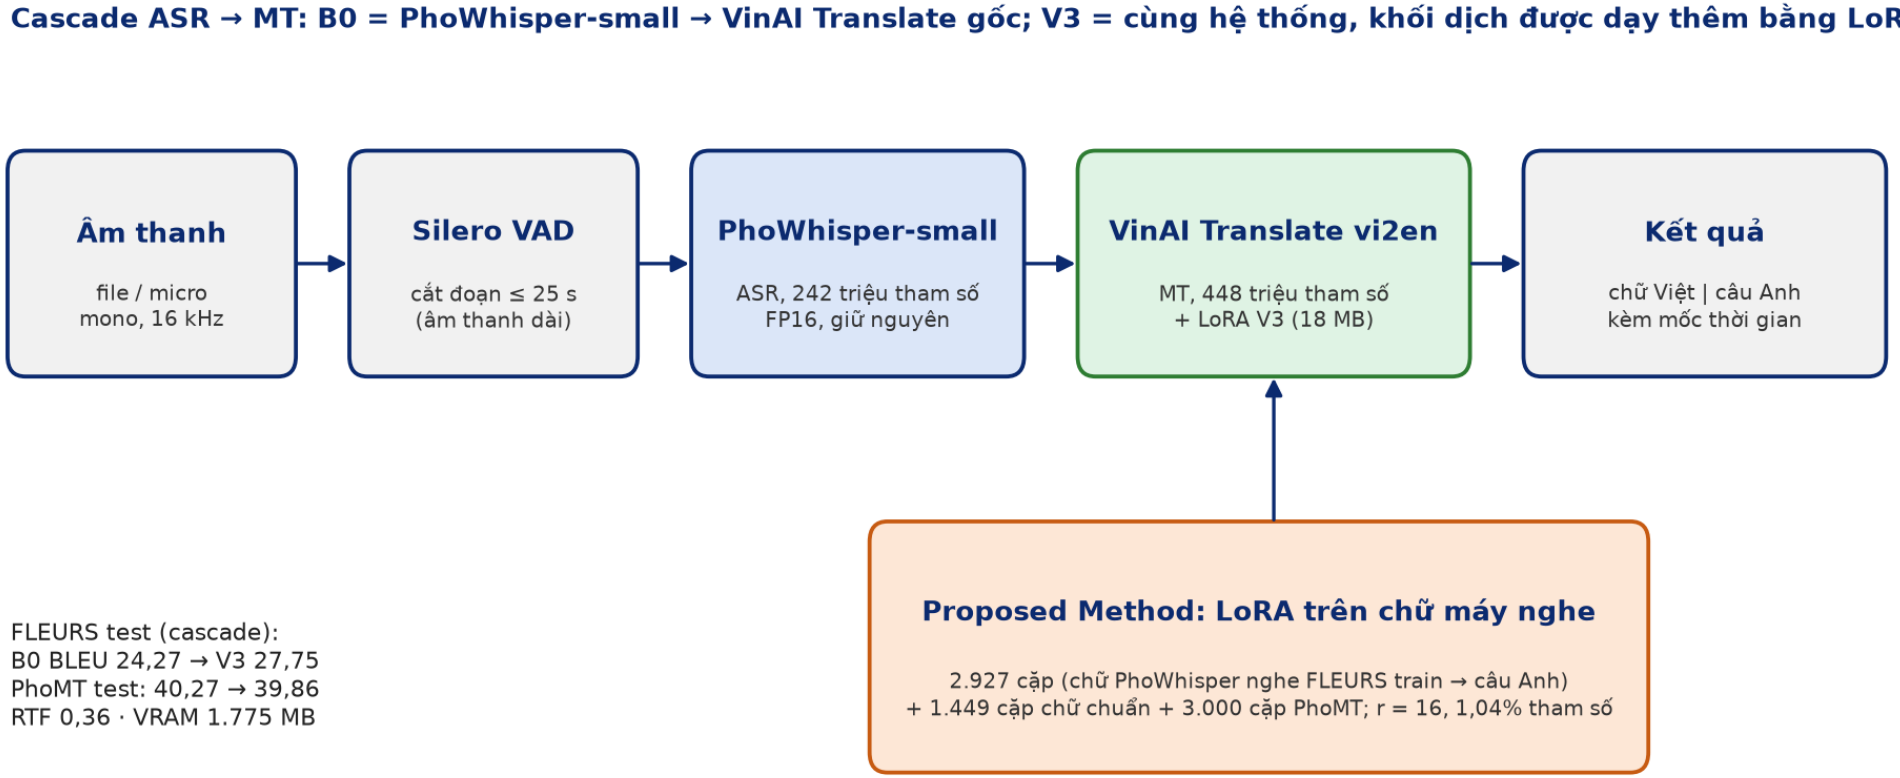
# Kết quả baseline theo nhóm dữ liệu

| VIVOS (PhoWhisper) | Số câu | WER |
|---|---|---|
| **Câu < 3 giây** | 237 | 8,60 |
| **Câu 3–5 giây** | 471 | 5,23 |
| **Câu ≥ 5 giây** | 52 | 8,56 |
| **Người nói tốt nhất** | VIVOSDEV19 | 0,78 |
| **Người nói kém nhất** | VIVOSDEV10 | 24,93 |

| FLEURS, cascade B0 | Số câu | BLEU |
|---|---|---|
| **Nghe đúng hoàn toàn** | 183 | 30,10 |
| **WER 0–10%** | 283 | 26,80 |
| **WER 10–30%** | 306 | 21,53 |
| **WER > 30%** | 85 | 10,55 |
| **Câu có chữ số** | 171 | 17,98 |

Câu ngắn dưới 3 giây sai nhiều hơn (ít ngữ cảnh). Độ khó giữa người nói chênh 30 lần — số trung bình che mất người nói khó.

# Proposed Method: kiến trúc (V1 → V3)



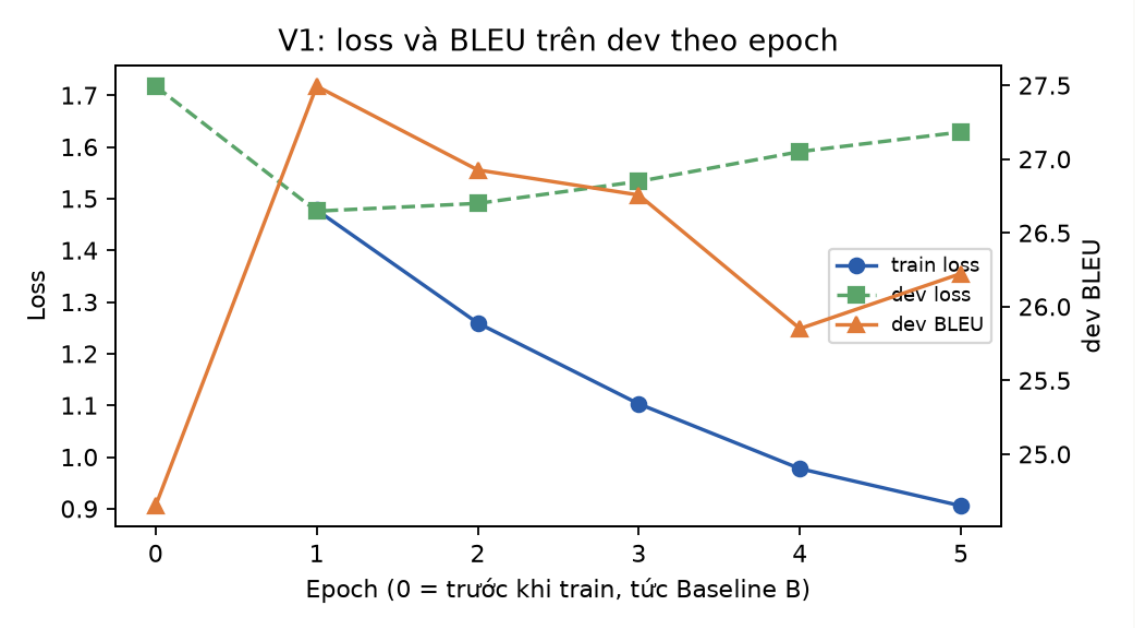

LoRA r 16. alpha 32. gắn vào q/k/v/out_proj · 4.718.592 / 453.144.576 tham số (1.04%) · V1: 2.927 cặp chữ máy nghe (WER 11.35%). chọn epoch trên 361 câu dev

# Kết quả V1 và tín hiệu cải thiện

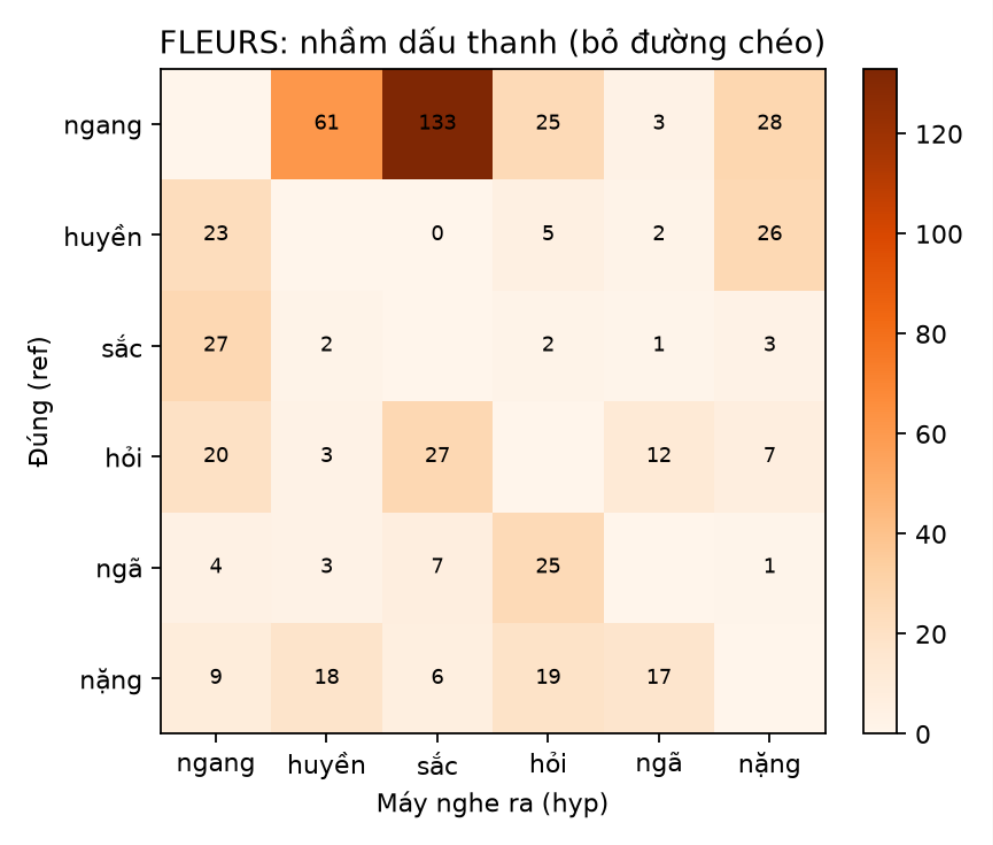
| Chỉ số (test) | B0 | V1 |
|---|---|---|
| **BLEU cascade FLEURS** | **24,27** | **28,59** |
| **chrF++ cascade** | 50,12 | 52,82 |
| **BLEU chữ chuẩn** | 37,85 | 37,31 |
| **BLEU PhoMT** | 40,27 | 37,90 |

## Tín hiệu cải thiện: CÓ

- ΔBLEU 4,36, khoảng tin cậy 95% [3,19; 5,48], p < 0,001
- Bootstrap 1.000 lần, lấy mẫu theo cụm câu gốc
- Mặt trái: PhoMT giảm, V1 quên văn bản sạch



# Lỗi nghe mà V1 chưa sửa được




Ma trận nhầm dấu thanh (bỏ đường chéo) thay cho Confusion Matrix của bài phân loại.

| Loại từ (FLEURS test) | Số từ | Nghe đúng |
|---|---|---|
| **Từ thường** | 23.976 | 95,2% |
| **Tên riêng** | 1.732 | 65,2% |
| **Tên nước ngoài** | **952** | **43,8%** |

## Ví dụ lỗi nghe còn lại

- "Aristotle" → "erik stone" (V1, V2 dịch theo tên sai)
- "802.11n" → "tám không hai chấm một một in": số đọc thành chữ
- Nhầm dấu thanh chỉ chiếm 5,7% lỗi thay thế trên FLEURS (12,1% trên VIVOS)

# Failure cases V1: lỗi dịch

| Nguyên nhân | Ví dụ / bằng chứng |
|---|---|
| **Số đọc thành chữ → sinh lặp** | Máy nghe "chuẩn tám không hai chấm một một … hai chấm bốn đi ra hệ" (đúng: 802.11n … 2.4GHz) → V1 lặp "one, one, two, one…" tới giới hạn độ dài |
| **Bỏ sót, đơn giản hóa** | "không nhất thiết phải cần" → V1 bỏ "necessarily"; "quần đảo" → "islands" thay vì "archipelagos" |
| **Quên văn bản sạch** | BLEU PhoMT 40,27 → 37,90 vì chỉ dạy trên FLEURS |
| **Thích nghi miền** | Câu nghe đúng hoàn toàn cũng tăng 5,62 BLEU: V1 còn quen văn phong FLEURS |

So từng câu với B0 (chênh chrF++ trên 1 điểm): V1 tốt lên 444 câu, kém đi 244 câu, như cũ 169 câu

# Đề xuất cải tiến V2, V3

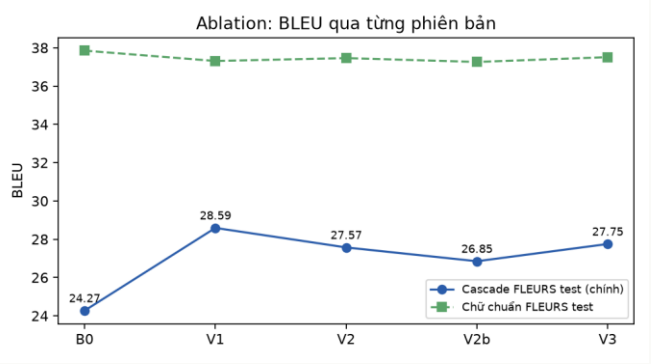
| Phiên bản | Thay đổi | Lý do (từ phân tích lỗi) | Dev BLEU | Quyết định |
|---|---|---|---|---|
| **V2** | + 1.449 cặp chữ chuẩn + 3.000 cặp PhoMT | V1 overfit, quên văn bản sạch | 27,17 | Nhận |
| **V2b** | V2 + cân bằng theo câu | Mất cân bằng số bản thu mỗi câu | 26,98 | Không: kém V2 |
| **V3a** | V2 + chuẩn hóa số khi dịch | Lỗi số đọc thành chữ | 27,29 → 27,17 | Không: dev giảm |
| **V3** | Chuẩn hóa số cả khi dạy lẫn khi dịch | V3a lệch dữ liệu dạy và dịch | 27,56 (so V2 27,29) | Nhận |

**Chọn bản cuối trên validation**

PhoMT dev (2.000 câu): B0 40,96 · V1 38,98 (giảm 1,98, loại) · V2 40,80 (giảm 0,16, đạt) · V3 41,16

# Ablation Study

| Phiên bản | BLEU cascade | chrF++ | Δ so với B0 | BLEU chữ chuẩn | BLEU PhoMT |
|---|---|---|---|---|---|
| **B0** | 24,27 | 50,12 | 0,00 | 37,85 | 40,27 |
| **V1** | 28,59 | 52,82 | +4,32 | 37,31 | 37,90 |
| **V2** | 27,57 | 52,44 | +3,30 | 37,46 | 39,80 |
| **V2b** | 26,85 | 52,12 | +2,58 | 37,26 | – |
| **V3** | **27,75** | **52,57** | **+3,48** | **37,51** | **39,86** |




| So với B0 | ΔBLEU | KTC 95% | p |
|---|---|---|---|
| **V1** | 4,36 | [3,19; 5,48] | < 0,001 |
| **V2** | 3,28 | [2,11; 4,49] | < 0,001 |
| **V2b** | 2,59 | [1,61; 3,64] | < 0,001 |
| **V3** | 3,49 | [2,34; 4,70] | < 0,001 |

**Độ ổn định theo seed (V3)**

- Seed 42 / 13 / 7: 27,75 / 27,32 / 27,80
- Trung bình 27,62 ± 0,26; kém nhất vẫn hơn B0 3,05
- V3 hơn V2 trên toàn tập nhỏ hơn dao động seed; đóng góp rõ ở câu có chữ số (+1,06)

# Kết quả đầu ra tiêu biểu

**V3 TỐT LÊN**

Máy nghe: chuẩn tám không hai chấm một một n hoạt động trên cả hai tần số hai chấm bốn ghi ra hệt và năm chấm không ghi ra hệt.
Tham chiếu: The 802.11n standard operates on both the 2.4Ghz and 5.0Ghz frequencies.
B0: standard eight zeros two dots one one one n works on both frequencies two dots four writes out exactly and five dots dots do not write out exactly.
**V3: The 802.11 n standard operates on both 2.4 GHz and 5.0 GHz frequencies.**

**V3 TỐT LÊN**

Máy nghe: vậy là có khả năng chú thích được thêm vào đơn giản chỉ là nhãn đánh dấu.
Tham chiếu: So, it is likely that the notation was added simply as a label.
B0: So there's a possibility that the footnotes are simply labels.
**V3: Thus, it is possible that the annotation was added simply as a mark label.**

**V3 VẪN SAI**

Máy nghe: lát kha xin cũng trình bày chắp ranh không hazard ca sĩ gây du khăn đeo góc hát cùng ông.
Tham chiếu: Lakkha Singh presented the chhappan bhog bhajan as well. Singer, Raju Khandelwal was accompanying him.
B0: He also performed "Cắp ranh không hazard" ["No Hazard"] with him.
**V3: He also performed "Crystals Without Hazard", where singer Zhao Yuen sings alongside him.**

# Tốc độ và dung lượng

| Chỉ số | B0 | V3 (bản cuối) |
|---|---|---|
| **RTF toàn hệ thống** | **0,315** | **0,358** |
| **RTF nghe / dịch** | 0,215 / 0,100 | 0,246 / 0,111 |
| **Độ trễ trung vị / p95 (giây)** | 3,73 / 6,67 | 4,29 / 6,99 |
| **VRAM đỉnh** | 1.791 MB | 1.775 MB |
| **Âm thanh dài 249 s: có VAD** | RTF 0,307 | RTF 0,274 |
| **Âm thanh dài 249 s: không VAD** | RTF 0,439 | RTF 0,433 |

| Dung lượng | Giá trị |
|---|---|
| **ASR** | 922 MB |
| **MT** | 1.711 MB |
| **Adapter LoRA** | 18 MB |
| **Tham số ASR** | 241,7 triệu |
| **Tham số MT** | 448,4 triệu |

NVIDIA GeForce RTX 4060 Laptop GPU · FP16 · từng câu một · không tính thời gian nạp mô hình.

# Đánh giá tính khả thi

| Tiêu chí | Ngưỡng (đặt trước) | Bản cuối V3 | Đạt? |
|---|---|---|---|
| **Chất lượng** | Hơn B0 trên cascade; PhoMT giảm ≤ 1 điểm | 27,75 so với 24,27; PhoMT dev 41,16 (B0 40,96) | Đạt |
| **Tốc độ** | RTF < 1 | 0,358 (âm thanh dài, VAD: 0,274) | Đạt |
| **Độ trễ** | Trung vị < 3 giây / câu | 4,29 giây (câu TB 12,8 giây) | Chưa |
| **Bộ nhớ** | VRAM < 8 GB | 1.775 MB | Đạt |
| **Âm thanh dài** | Có VAD, xử lý vài phút | 249 giây, 11 đoạn | Đạt |

**KHẢ THI**

Triển khai dự kiến ở Task 3: web Gradio trên máy có GPU (laptop RTX 4060 hoặc Hugging Face Spaces có GPU)
Hạn chế: chưa thử micro điện thoại và giọng nữ ở tập test; tên nước ngoài và số đọc thành chữ vẫn là điểm yếu

# Kế hoạch thực hiện Task 3

| Hạng mục | Nội dung | Phụ trách |
|---|---|---|
| **Demo Gradio (bắt buộc)** | Tab tải file và tab micro; hiển thị song song Việt \| Anh kèm mốc thời gian | Đăng |
| **Real-time, âm thanh dài** | VAD cắt đoạn ngắn để giảm độ trễ; hiển thị theo từng đoạn | Đăng, Bảo |
| **API (điểm cộng)** | FastAPI /transcribe, /translate, /speech-translate; schema, xử lý lỗi | Kiệt |
| **Docker, CI/CD (điểm cộng)** | Dockerfile, GitHub Actions, deploy Hugging Face Spaces | Kiệt |
| **Cải tiến mô hình** | Tên riêng, số đọc thành chữ; thử giọng nữ, micro điện thoại | Bảo, Kiệt |
| **Báo cáo cuối, video** | Báo cáo 15–25 trang; video demo 2–5 phút; bảng đóng góp | Uyên, cả nhóm |

# Cảm ơn thầy và các bạn

Q&A

Code, số liệu và nhật ký thực nghiệm: github.com/lekithaha06/DPL302m