ĐỀ TÀI 1 · DPL302M · TASK 2

Hệ thống nhận dạng giọng nói tiếng Việt kèm dịch sang tiếng Anh

Báo cáo Tiến độ Task 2: Xử lý Dữ liệu, Thực nghiệm Baseline & Mô hình Đề xuất

Dương Gia Bảo · Lê Tuấn Kiệt · Hồ Lâm Bảo Đăng · Bùi Ngọc Phương Uyên
Mã nhóm: ..... · GVHD: .....

Tổng quan nội dung

I	**Xử lý và phân tích dữ liệu** Nguồn, làm sạch, gán nhãn, thống kê, mất cân bằng	**Uyên · Đăng**	slide 3–7
II	**Thực nghiệm hai baseline** Môi trường, Paper và Nhóm, Gap Analysis, theo nhóm dữ liệu	**Bảo · Kiệt · Uyên**	slide 8–12
III	**Proposed Method V1 → V3** Kiến trúc, kết quả, failure cases, V2/V3, ablation	**Kiệt · Bảo**	slide 13–18
IV	**Lỗi và tính khả thi** Kết quả đầu ra, tốc độ, dung lượng, khả thi, kế hoạch Task 3	**Đăng**	slide 19–22

Thu thập và tổng quan dữ liệu

Nguồn	Loại	Số mẫu dùng	Định dạng	Dung lượng	License
FLEURS vi_vn + en_us	Online	2.994 / 361 / 857 bản thu (train/dev/test)	WAV 16 kHz + TSV	2,9 GB	CC BY 4.0
VIVOS (test)	Online	760 câu, 19 người nói	WAV 16 kHz + TXT	82 MB	CC BY-NC-SA 4.0
PhoMT	Online (gated)	2.977.999 / 18.719 / 19.151 cặp câu	TXT song song	501 MB	Chỉ nghiên cứu
Tự thu	Offline	Không thu thập	–	–	–

Các trường dữ liệu FLEURS: ID câu FLoRes · tên file · transcript gốc · transcript chuẩn hóa · số mẫu âm thanh · giới tính

VÍ DỤ MẪU FLEURS

Âm thanh: 11154206868753468740.wav · ID câu 1262

Tiếng Việt: Ở thành phố Harappa và Mohenjo-daro, hầu như nhà nào cũng có cầu tiêu xối nước nối vào một hệ thống cống rãnh phức tạp.

Tiếng Anh: The cities of Harappa and Mohenjo-daro had a flush toilet in almost every house, attached to a sophisticated sewage system.

Làm sạch dữ liệu

Dữ liệu gốc	Có câu Anh	Transcript	Âm thanh	Không trùng
vi_vn TSV	ghép theo ID	không rỗng	đọc được	hash SHA-1
2.994	**2.927**	**2.927**	**2.927**	**2.927**

Số bản thu còn lại của tập train sau mỗi bước (dev 361 và test 857 không mất mẫu nào)

Bước	Cách làm
Missing values	Bỏ bản thu không có câu tiếng Anh cùng ID FLoRes: train loại 67 (2,2%)
Duplicate	So hash từng file âm thanh: 0 file trùng. Một câu có nhiều bản thu là thiết kế của FLEURS, không phải trùng
Noise / outlier	Giữ lại để phân tích: 4 bản thu train và 2 dev dài hơn 30 giây
Chuẩn hóa	100% âm thanh 16 kHz; chữ: NFC, viết thường, ký hiệu thành khoảng trắng, giữ dấu tiếng Việt
Chống leakage	Chia theo ID câu; train–dev, train–test, dev–test: 0 ID trùng, 0 câu trùng nội dung

Gán nhãn và độ đồng nhất

Dataset	Nhãn dùng
FLEURS	Transcript tiếng Việt gốc + câu tiếng Anh FLoRes cùng ID (bản dịch chuyên nghiệp)
VIVOS	Transcript gốc của bộ dữ liệu, chia theo người nói
PhoMT	Cặp câu song ngữ gốc

Gán nhãn loại lỗi cho 100 câu FLEURS dev mà baseline nghe hoặc dịch sai (chọn tự động, seed 42)

Sai dấu thanh	Tên riêng	Số	Thiếu / thừa từ	Sai nghĩa

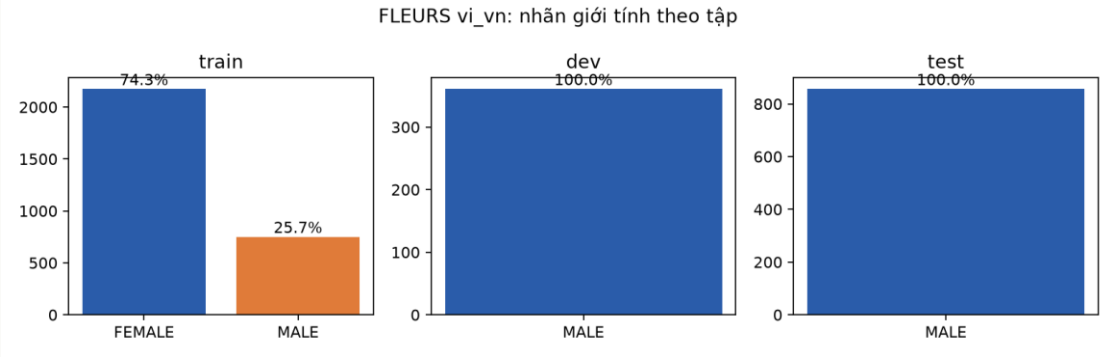
Gán tự động (100 câu)	Dấu thanh	Tên riêng	Số	Thiếu/thừa từ	Sai nghĩa
Số câu có lỗi	21 (21%)	43 (43%)	17 (17%)	26 (26%)	31 (31%)

73/100 câu có ít nhất một lỗi. Nhãn gán tự động theo quy tắc cố định (chạy lại ra đúng kết quả); chỉ một quy trình gán nên không tính Cohen's Kappa.

Đề Task 2 mục 1.2: Kappa chỉ bắt buộc nếu có quy trình nhiều người gán nhãn. Tiêu chí: reports/task2/labeling/TIEU_CHI_GAN_NHAN.md

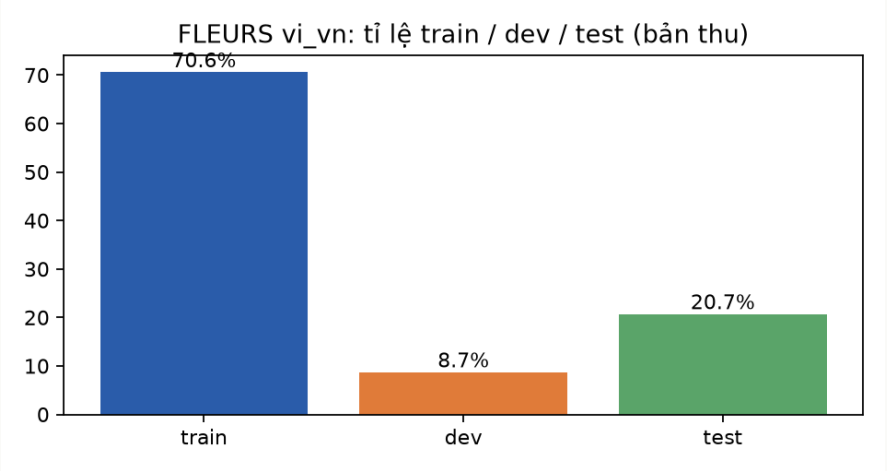
Thống kê mô tả và mất cân bằng

	Train	Dev	Test
Bản thu	2.927	361	857
Câu gốc	1.449	149	347
Giờ	8,86	1,19	3,00
TB giây/câu	10,9	11,9	12,6
Tỉ lệ	70,6%	8,7%	20,7%

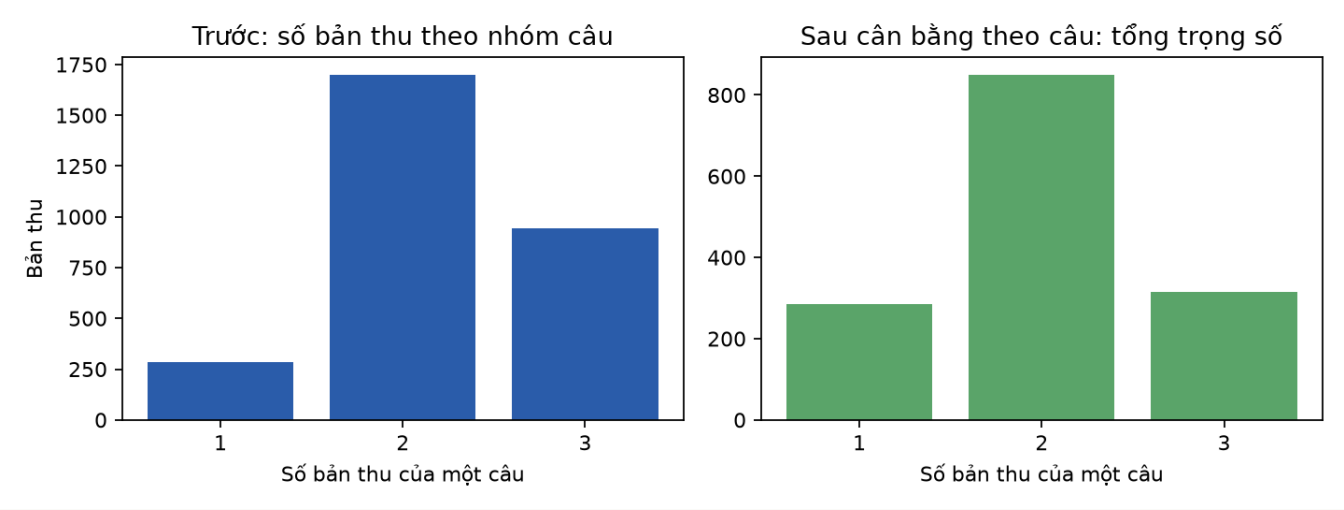


Nhận xét định lượng

- Giới tính: train 2.175 giọng nữ (74.3%). dev và test 100% giọng nam
- Số bản thu mỗi câu (train): 285 câu có 1, 850 câu có 2, 314 câu có 3
- Độ dài: 52,4% bản thu train dài 10–20 giây, chỉ 63 bản dưới 5 giây
- PhoMT: 51,4% train là phụ đề phim (paper PhoMT)



Xử lý mất cân bằng



Kỹ thuật áp dụng

- Resampling theo câu: bản thu của câu có k bản được lấy với trọng số 1/k
- Cân bằng miền khi trộn dữ liệu (V2): thêm 1.449 cặp chữ chuẩn và 3.000 cặp PhoMT
- Không augmentation âm thanh: không train khối nghe
- Lệch giới tính: test không có giọng nữ, ghi là hạn chế

KẾT QUẢ ĐO

V2b (V2 + cân bằng theo câu): dev 26,98 so với V2 27,17; test cascade 26,85 so với 27,57

→ Không cải thiện, không dùng trong bản cuối

Hình trái: trước (số bản thu theo nhóm câu) và sau cân bằng (tổng trọng số); FLEURS train.

Cấu hình môi trường thực nghiệm

Thành phần	Giá trị
Phần cứng	NVIDIA GeForce RTX 4060 Laptop GPU (8 GB) — một máy cho mọi số so sánh và đo tốc độ
Framework	Python 3.11.1 · PyTorch 2.6.0+cu124 · Transformers 5.17.0 · PEFT 0.21.2 · sacreBLEU 2.6.0
Seed / độ chính xác	42 · suy luận FP16, train bf16
Baseline A (ASR)	PhoWhisper-small, Whisper-small · beam 5 · batch 1 · tiếng Việt
Baseline B (MT)	VinAI Translate vi2en (bản của paper) · beam 5
LR · optimizer · epoch	Baseline: không áp dụng (zero-shot, không train)
V1 → V3 (LoRA)	AdamW · lr 2e-04 · warmup 6% · batch 8×2 · r 16 · alpha 32 · tối đa 3–5 epoch, chọn theo dev

Baseline A: Paper và thực nghiệm của nhóm

Mô hình	Nguồn	Dataset	WER	CER
PhoWhisper-small	Paper (Table 2)	VIVOS test	6,33	–
PhoWhisper-small	**Nhóm**	**VIVOS test (760)**	**6,25**	**3,26**
Whisper-small	Nhóm (zero-shot)	VIVOS test (760)	22,26	13,15
PhoWhisper-small	Nhóm	FLEURS test (857)	12,29	8,68
Whisper-small	Nhóm (zero-shot)	FLEURS test (857)	21,42	12,56

Tách lỗi WER của PhoWhisper-small (thay thế / xóa / chèn)

- VIVOS: 447 / 22 / 14 trên 7.722 từ
- FLEURS: 2.057 / 136 / 1.006 trên 26.021 từ — lỗi chèn nhiều bất thường (xem slide 11)

Baseline B: Paper và thực nghiệm của nhóm

Mô hình	Nguồn	Dataset	BLEU	chrF++
VinAI Translate vi2en	Paper (Table 1)	PhoMT test	40,42	–
VinAI Translate vi2en	Nhóm	PhoMT test (19.151)	40,27	60,32
Dịch chữ chuẩn	Nhóm	FLEURS test (857)	37,85	61,16
Cascade A → B (B0)	**Nhóm**	**FLEURS test (857)**	**24,27**	**50,12**

−13,58

BLEU mất đi khi thay chữ chuẩn bằng chữ máy nghe

Đây là vấn đề Proposed Method nhắm tới. Không dùng vinai-translate-vi2en-v2: khoảng 10 nghìn cặp train của bản này nằm trong PhoMT test.

Gap Analysis

Nguyên nhân	Bằng chứng	Ảnh hưởng
Khớp công bố	PhoWhisper 6,25 so với 6,33 · VinAI 40,27 so với 40,42	Chênh dưới 0,2 điểm: tái lập thành công
Domain gap	VIVOS 6,25% (cùng miền, PhoWhisper đã học VIVOS train) so với FLEURS 12,21%	FLEURS câu dài hơn (12,6 s so với 3,5 s), đọc văn bản Wikipedia
Tiền xử lý / chuẩn hóa	Từ bị chèn nhiều nhất trên FLEURS là số: một, hai, trăm, mươi ("802" → "tám trăm linh hai")	WER FLEURS bị đội lên vì khác cách viết số, không hoàn toàn do nghe sai
Môi trường / giải mã	Whisper-small 25,91% (Task 1) → 22,26%: 750/760 câu giống hệt; câu R193 hết sinh lặp (293 → 4 từ)	PhoWhisper 760/760 câu giống hệt: kết quả ổn định
Cách gom câu khi dịch	B0 cascade 24,21 → 24,27 khi đổi batch để tránh tràn bộ nhớ	Mọi phiên bản chấm cùng một script và cấu hình

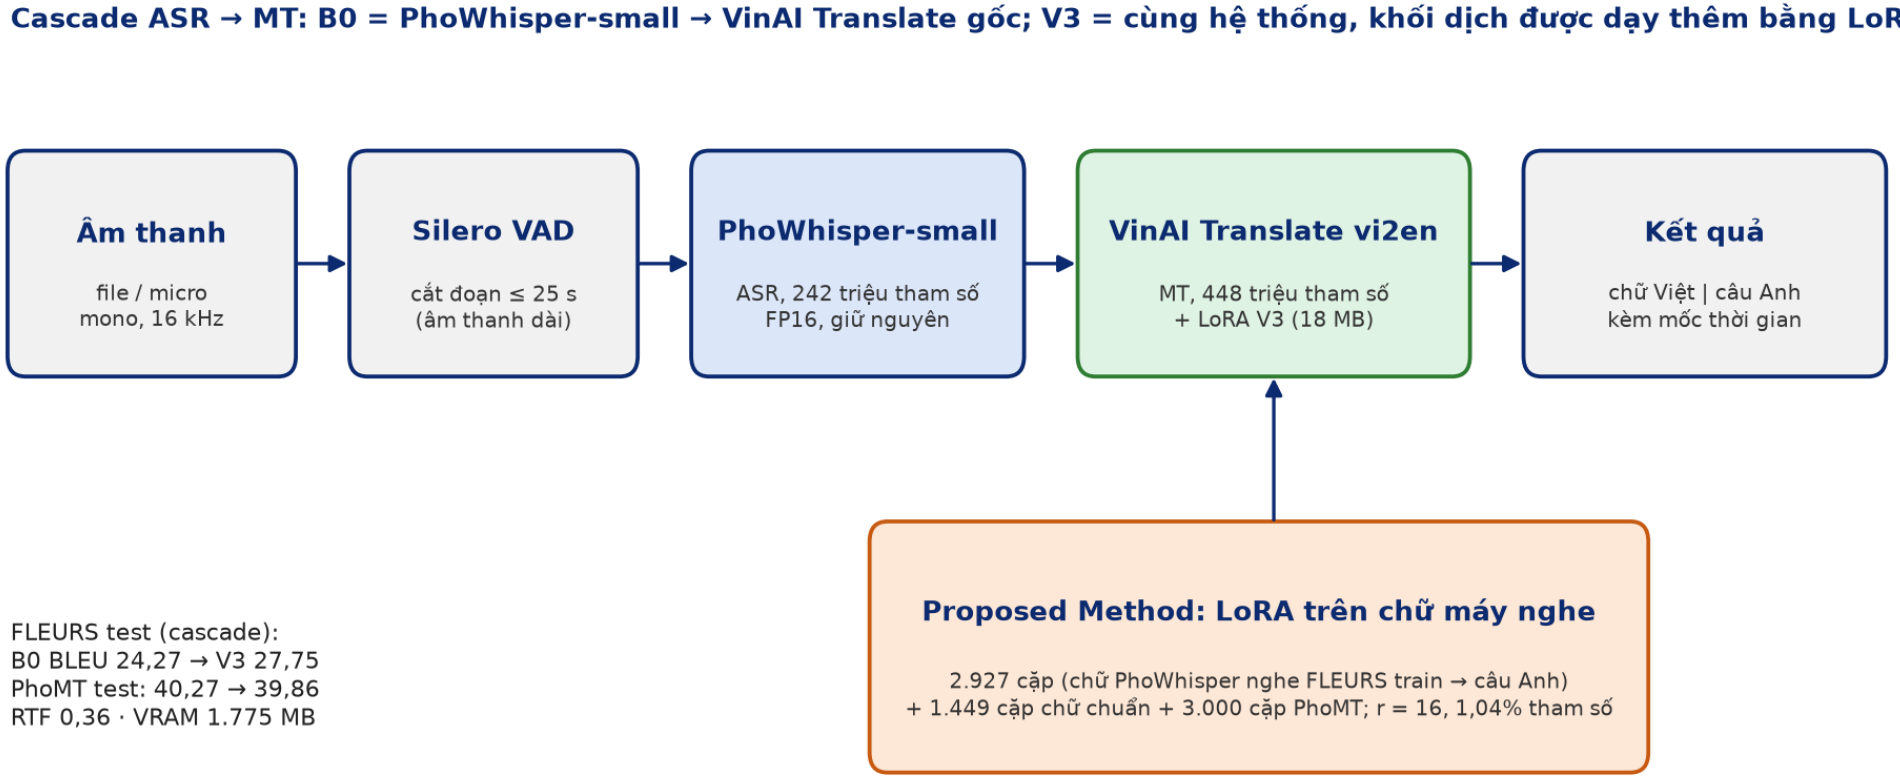
Kết quả baseline theo nhóm dữ liệu

VIVOS (PhoWhisper)	Số câu	WER
Câu < 3 giây	237	8,60
Câu 3–5 giây	471	5,23
Câu ≥ 5 giây	52	8,56
Người nói tốt nhất	VIVOSDEV19	0,78
Người nói kém nhất	VIVOSDEV10	24,93

FLEURS, cascade B0	Số câu	BLEU
Nghe đúng hoàn toàn	183	30,10
WER 0–10%	283	26,80
WER 10–30%	306	21,53
WER > 30%	85	10,55
Câu có chữ số	171	17,98

Câu ngắn dưới 3 giây sai nhiều hơn (ít ngữ cảnh). Độ khó giữa người nói chênh 30 lần — số trung bình che mất người nói khó.

Proposed Method: kiến trúc (V1 → V3)



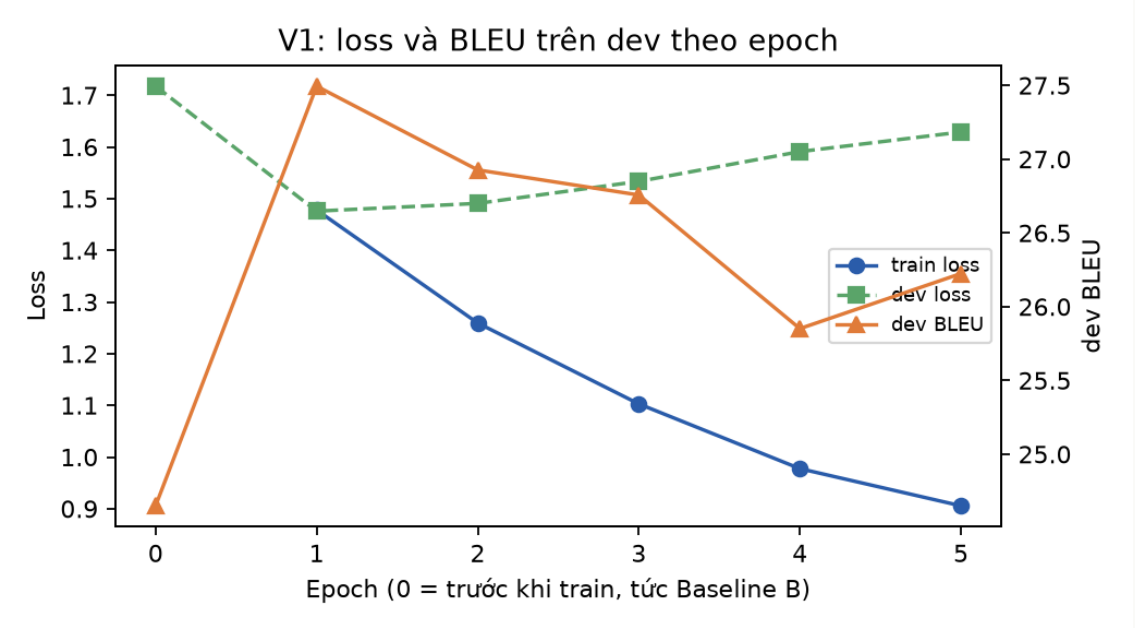
LoRA r 16. alpha 32. gắn vào q/k/v/out_proj · 4.718.592 / 453.144.576 tham số (1.04%) · V1: 2.927 cặp chữ máy nghe (WER 11.35%). chọn epoch trên 361 câu dev

Kết quả V1 và tín hiệu cải thiện

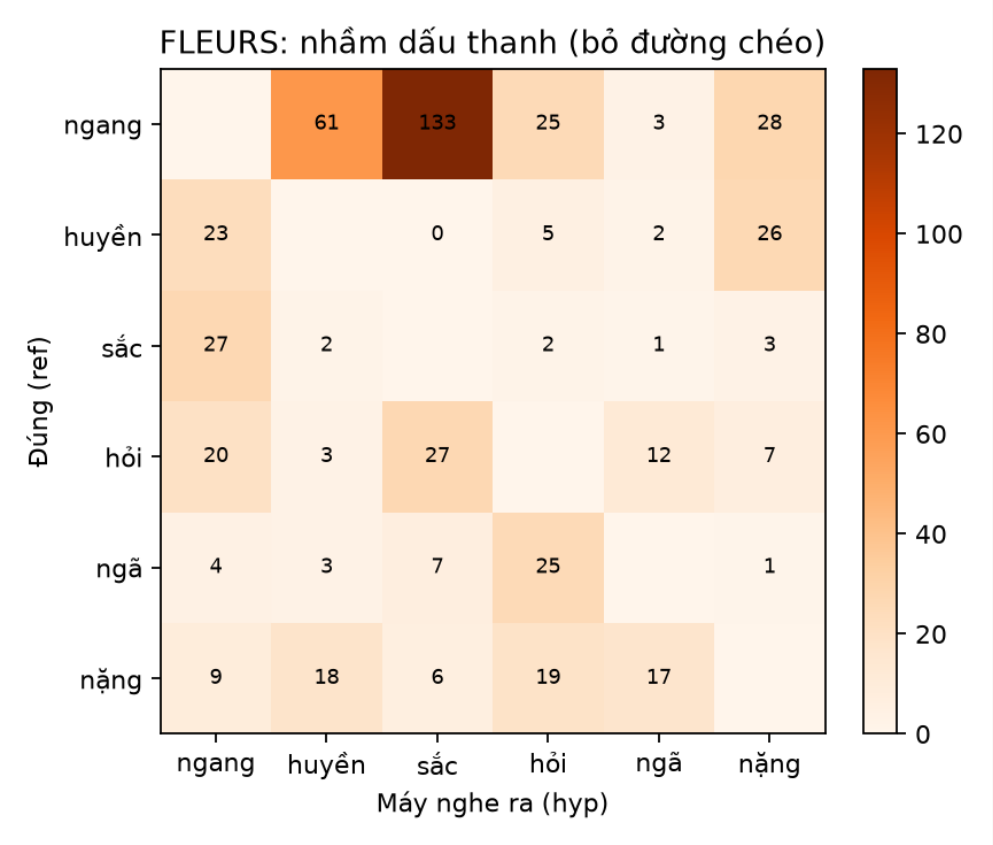
Chỉ số (test)	B0	V1
BLEU cascade FLEURS	**24,27**	**28,59**
chrF++ cascade	50,12	52,82
BLEU chữ chuẩn	37,85	37,31
BLEU PhoMT	40,27	37,90

Tín hiệu cải thiện: CÓ

- ΔBLEU 4,36, khoảng tin cậy 95% [3,19; 5,48], p < 0,001
- Bootstrap 1.000 lần, lấy mẫu theo cụm câu gốc
- Mặt trái: PhoMT giảm, V1 quên văn bản sạch



Lỗi nghe mà V1 chưa sửa được



Ma trận nhầm dấu thanh (bỏ đường chéo) thay cho Confusion Matrix của bài phân loại.

Loại từ (FLEURS test)	Số từ	Nghe đúng
Từ thường	23.976	95,2%
Tên riêng	1.732	65,2%
Tên nước ngoài	**952**	**43,8%**

Ví dụ lỗi nghe còn lại

- "Aristotle" → "erik stone" (V1, V2 dịch theo tên sai)
- "802.11n" → "tám không hai chấm một một in": số đọc thành chữ
- Nhầm dấu thanh chỉ chiếm 5,7% lỗi thay thế trên FLEURS (12,1% trên VIVOS)

Failure cases V1: lỗi dịch

Nguyên nhân	Ví dụ / bằng chứng
Số đọc thành chữ → sinh lặp	Máy nghe "chuẩn tám không hai chấm một một … hai chấm bốn đi ra hệ" (đúng: 802.11n … 2.4GHz) → V1 lặp "one, one, two, one…" tới giới hạn độ dài
Bỏ sót, đơn giản hóa	"không nhất thiết phải cần" → V1 bỏ "necessarily"; "quần đảo" → "islands" thay vì "archipelagos"
Quên văn bản sạch	BLEU PhoMT 40,27 → 37,90 vì chỉ dạy trên FLEURS
Thích nghi miền	Câu nghe đúng hoàn toàn cũng tăng 5,62 BLEU: V1 còn quen văn phong FLEURS

So từng câu với B0 (chênh chrF++ trên 1 điểm): V1 tốt lên 444 câu, kém đi 244 câu, như cũ 169 câu

Đề xuất cải tiến V2, V3

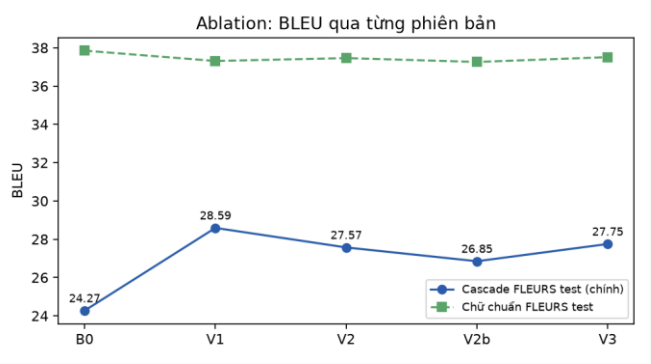
Phiên bản	Thay đổi	Lý do (từ phân tích lỗi)	Dev BLEU	Quyết định
V2	+ 1.449 cặp chữ chuẩn + 3.000 cặp PhoMT	V1 overfit, quên văn bản sạch	27,17	Nhận
V2b	V2 + cân bằng theo câu	Mất cân bằng số bản thu mỗi câu	26,98	Không: kém V2
V3a	V2 + chuẩn hóa số khi dịch	Lỗi số đọc thành chữ	27,29 → 27,17	Không: dev giảm
V3	Chuẩn hóa số cả khi dạy lẫn khi dịch	V3a lệch dữ liệu dạy và dịch	27,56 (so V2 27,29)	Nhận

Chọn bản cuối trên validation

PhoMT dev (2.000 câu): B0 40,96 · V1 38,98 (giảm 1,98, loại) · V2 40,80 (giảm 0,16, đạt) · V3 41,16

Ablation Study

Phiên bản	BLEU cascade	chrF++	Δ so với B0	BLEU chữ chuẩn	BLEU PhoMT
B0	24,27	50,12	0,00	37,85	40,27
V1	28,59	52,82	+4,32	37,31	37,90
V2	27,57	52,44	+3,30	37,46	39,80
V2b	26,85	52,12	+2,58	37,26	–
V3	**27,75**	**52,57**	**+3,48**	**37,51**	**39,86**



So với B0	ΔBLEU	KTC 95%	p
V1	4,36	[3,19; 5,48]	< 0,001
V2	3,28	[2,11; 4,49]	< 0,001
V2b	2,59	[1,61; 3,64]	< 0,001
V3	3,49	[2,34; 4,70]	< 0,001

Độ ổn định theo seed (V3)

- Seed 42 / 13 / 7: 27,75 / 27,32 / 27,80
- Trung bình 27,62 ± 0,26; kém nhất vẫn hơn B0 3,05
- V3 hơn V2 trên toàn tập nhỏ hơn dao động seed; đóng góp rõ ở câu có chữ số (+1,06)

Kết quả đầu ra tiêu biểu

V3 TỐT LÊN

Máy nghe: chuẩn tám không hai chấm một một n hoạt động trên cả hai tần số hai chấm bốn ghi ra hệt và năm chấm không ghi ra hệt.
Tham chiếu: The 802.11n standard operates on both the 2.4Ghz and 5.0Ghz frequencies.
B0: standard eight zeros two dots one one one n works on both frequencies two dots four writes out exactly and five dots dots do not write out exactly.
V3: The 802.11 n standard operates on both 2.4 GHz and 5.0 GHz frequencies.

V3 TỐT LÊN

Máy nghe: vậy là có khả năng chú thích được thêm vào đơn giản chỉ là nhãn đánh dấu.
Tham chiếu: So, it is likely that the notation was added simply as a label.
B0: So there's a possibility that the footnotes are simply labels.
V3: Thus, it is possible that the annotation was added simply as a mark label.

V3 VẪN SAI

Máy nghe: lát kha xin cũng trình bày chắp ranh không hazard ca sĩ gây du khăn đeo góc hát cùng ông.
Tham chiếu: Lakkha Singh presented the chhappan bhog bhajan as well. Singer, Raju Khandelwal was accompanying him.
B0: He also performed "Cắp ranh không hazard" ["No Hazard"] with him.
V3: He also performed "Crystals Without Hazard", where singer Zhao Yuen sings alongside him.

Tốc độ và dung lượng

Chỉ số	B0	V3 (bản cuối)
RTF toàn hệ thống	**0,315**	**0,358**
RTF nghe / dịch	0,215 / 0,100	0,246 / 0,111
Độ trễ trung vị / p95 (giây)	3,73 / 6,67	4,29 / 6,99
VRAM đỉnh	1.791 MB	1.775 MB
Âm thanh dài 249 s: có VAD	RTF 0,307	RTF 0,274
Âm thanh dài 249 s: không VAD	RTF 0,439	RTF 0,433

Dung lượng	Giá trị
ASR	922 MB
MT	1.711 MB
Adapter LoRA	18 MB
Tham số ASR	241,7 triệu
Tham số MT	448,4 triệu

NVIDIA GeForce RTX 4060 Laptop GPU · FP16 · từng câu một · không tính thời gian nạp mô hình.

Đánh giá tính khả thi

Tiêu chí	Ngưỡng (đặt trước)	Bản cuối V3	Đạt?
Chất lượng	Hơn B0 trên cascade; PhoMT giảm ≤ 1 điểm	27,75 so với 24,27; PhoMT dev 41,16 (B0 40,96)	Đạt
Tốc độ	RTF < 1	0,358 (âm thanh dài, VAD: 0,274)	Đạt
Độ trễ	Trung vị < 3 giây / câu	4,29 giây (câu TB 12,8 giây)	Chưa
Bộ nhớ	VRAM < 8 GB	1.775 MB	Đạt
Âm thanh dài	Có VAD, xử lý vài phút	249 giây, 11 đoạn	Đạt

KHẢ THI

Triển khai dự kiến ở Task 3: web Gradio trên máy có GPU (laptop RTX 4060 hoặc Hugging Face Spaces có GPU)
Hạn chế: chưa thử micro điện thoại và giọng nữ ở tập test; tên nước ngoài và số đọc thành chữ vẫn là điểm yếu

Kế hoạch thực hiện Task 3

Hạng mục	Nội dung	Phụ trách
Demo Gradio (bắt buộc)	Tab tải file và tab micro; hiển thị song song Việt | Anh kèm mốc thời gian	Đăng
Real-time, âm thanh dài	VAD cắt đoạn ngắn để giảm độ trễ; hiển thị theo từng đoạn	Đăng, Bảo
API (điểm cộng)	FastAPI /transcribe, /translate, /speech-translate; schema, xử lý lỗi	Kiệt
Docker, CI/CD (điểm cộng)	Dockerfile, GitHub Actions, deploy Hugging Face Spaces	Kiệt
Cải tiến mô hình	Tên riêng, số đọc thành chữ; thử giọng nữ, micro điện thoại	Bảo, Kiệt
Báo cáo cuối, video	Báo cáo 15–25 trang; video demo 2–5 phút; bảng đóng góp	Uyên, cả nhóm

Cảm ơn thầy và các bạn

Q&A

Code, số liệu và nhật ký thực nghiệm: github.com/lekithaha06/DPL302m